

BibOps

Banc d'évaluation et d'optimisation de LLM pour le support IT

Comparaison LLM unique, agent ReAct outillé, agents A2A et évaluation adversariale

Encadrant : Emilien Mottet, SRE, Michelin

Équipe : Mohammed Akram Lrhorfi, Widad Benkhadra, Ayoub Touati

Dépôt : BibOps-michelin-ensimag-aginix

Date : Printemps 2026

Les identifiants fournis pour les agents A2A ne sont pas reproduits dans le rapport afin d'éviter toute diffusion de secrets.

Table des matières

Résumé	1
1 Introduction	2
1.1 Contexte industriel	2
1.2 Problématique	2
1.3 Objectifs	2
1.4 Contributions	2
2 Problématique	4
2.1 Nature des tickets de support IT	4
2.2 Limites du LLM unique	4
2.3 Intérêt de l'approche agentique	4
3 Présentation de la solution	5
3.1 Vue d'ensemble	5
3.2 Agent de support IT	5
3.3 Évaluation	7
3.4 A2A, MCP et Racing Arena	7
3.5 Reproductibilité	7
4 Organisation de l'équipe et synchronisation Git	9
4.1 Répartition du travail	9
4.2 Méthode de collaboration et pipeline CI/CD	11
5 Patrons de conception	13
5.1 Choix de conception	13
5.2 Le système vise plusieurs acteurs : [Cas d'utilisation]	13
5.3 Les concepts métier : [Diagramme de classes d'analyse]	13
6 Résultats	16
6.1 Conditions expérimentales	16
6.2 LLM unique contre agent ReAct	16
6.3 Benchmark MCP	17
6.4 Agents A2A	17
6.5 Kaggle local	20
6.6 Biais de position	20
6.7 Racing Arena adversariale	21
7 Discussion	23
7.1 Interprétation des résultats	23
7.2 Limites	23
7.3 Perspectives	23
8 Conclusion	24

Table des figures

3.1	Vue d'ensemble UML de l'architecture BIBOPS.	5
3.2	Boucle ReAct UML de l'agent de support IT.	6
4.1	Planification Gantt du projet sous PlantUML.	10
4.2	Pipeline Git, CI/CD et production des artefacts.	12
5.1	Diagramme des cas d'utilisation de BIBOPS.	14
5.2	Diagramme de classes d'analyse.	15
6.1	Synthèse du benchmark MCP avec score et latence sur échelles séparées.	17
6.2	Synthèse du benchmark A2A.	18
6.3	Synthèse du benchmark Kaggle local, modèle et juge inclus dans le titre du graphique.	20
6.4	Test de biais de position sur tickets IT et statements.	21
6.5	Rapport de sécurité de la Racing Arena.	21

Liste des tableaux

3.1	Organisation fonctionnelle du dépôt.	6
3.2	Outils disponibles pour l’agent IT.	6
3.3	Pondération de la politique composite.	7
5.1	Patrons de conception principaux.	13
6.1	Sources chiffrées exploitées.	16
6.2	Résultats principaux de <code>comparison_results.json</code>	16
6.3	Détail des cinq cas MCP. KB correspond à <code>mcp_chercher_dans_kb</code>	17
6.4	Synthèse des benchmarks MCP.	17
6.5	Métriques A2A détaillées. Les modèles non révélés sont des estimations ; <code>fs</code> désigne l’outil filesystem.	19
6.6	Erreurs restantes du dernier benchmark Kaggle local.	20
6.7	Résultats de biais de position.	21
6.8	Métriques de sécurité adversariale du dernier rapport Racing.	21
6.9	Efficacité observée par type d’attaque.	22

Résumé

Les grands modèles de langage sont aujourd’hui utilisables pour assister le support informatique : classification de tickets, aide au diagnostic, recherche dans une base de connaissances ou rédaction de réponses utilisateur. Dans un contexte industriel comme Michelin, cette promesse doit cependant être évaluée avec rigueur. La qualité apparente d’une réponse ne suffit pas : il faut aussi mesurer la sécurité, la latence, le coût, la dépendance fournisseur et l’empreinte environnementale.

Le projet BIBOPS construit un banc d’évaluation reproductible pour ce problème. Il compare une architecture *LLM unique*, appelée directement sur un ticket, à un agent ReAct outillé. L’agent peut vérifier un statut serveur dans SQLite, chercher dans une base de connaissances JSON et interroger une documentation technique via ChromaDB. Le projet ajoute aussi des benchmarks A2A, des tests de biais, un moteur d’évaluation multi-critères et une Racing Arena adversariale permettant d’étudier des agents connectés à un flux temps réel.

L’évaluation **21 tickets IT** [Table 6.2]. Avec `phi3:latest` côté Ollama et `gpt-5.2` comme juge, le système multi-agents obtient **7,86/10** en qualité moyenne contre **2,81/10** pour le LLM unique. Le score composite atteint **91,34/100** avec un verdict **PASS**, contre **46,14/100** et **FAIL** pour le LLM unique. L’architecture agentique réduit aussi la latence totale de **99,8 %**, le coût estimé de **60,6 %** et le nombre de tokens de **63,8 %**. Ces chiffres valident l’intérêt d’une architecture outillée pour les tickets qui dépendent d’un état ou d’une procédure interne.

Le résultat doit rester nuancé. La faible latence de l’agent est obtenue dans une configuration expérimentale où le premier outil est forcé et où certaines réponses sont synthétisées de façon déterministe à partir du résultat outil. Le rapport conclut donc que l’approche est prometteuse et mesurable, pas qu’elle peut remplacer telle quelle un support IT humain. La Racing Arena renforce cette prudence : une équipe ReAct exposée à des messages adversariaux exécute **53 injections sur 57 attaques reçues**, tandis qu’une équipe validée n’exécute aucune injection dans le scénario observé.

Mots-clés : LLM, support IT, ReAct, RAG, A2A, MCP, évaluation, sécurité agentique, CI/CD, GreenOps, PII, prompt injection, adversarial testing.

1. Introduction

1.1 Contexte industriel

Les assistants fondés sur des LLM peuvent accélérer le support IT en produisant un diagnostic initial, en reformulant une procédure, en suggérant une escalade ou en résumant un incident. Le cas Michelin ajoute des contraintes concrètes : les tickets peuvent contenir des données sensibles, les réponses doivent rester traçables, et l'outil doit fonctionner dans un environnement où coût, latence et dépendance fournisseur sont des critères de décision. Cette exigence rejoint les cadres de gestion du risque IA, notamment le NIST AI Risk Management Framework [10] et le règlement européen sur l'intelligence artificielle [4], qui insistent sur la traçabilité, la maîtrise des risques et la gouvernance des systèmes déployés.

L'usage brut d'un LLM est donc insuffisant comme objet d'étude. Une réponse fluide peut être fausse, inventer une procédure ou ignorer un état de service local. À l'inverse, un modèle plus petit peut devenir acceptable s'il est correctement outillé, cadré par des prompts robustes et évalué dans un pipeline reproductible. C'est l'hypothèse centrale du projet.

1.2 Problématique

La question traitée est la suivante :

Comment concevoir un banc d'évaluation reproductible permettant de comparer des LLM et des architectures agentiques pour des cas d'usage de support IT, tout en tenant compte de la qualité, de la sécurité, de la latence, du coût et de l'impact environnemental ?

Cette question impose de travailler à deux niveaux. Le premier est fonctionnel : le système doit répondre à des tickets IT. Le second est méthodologique : les résultats doivent être quantifiés, historisés et comparables d'une campagne à l'autre.

1.3 Objectifs

Le projet s'organise autour de quatre objectifs.

- O1. Construire un jeu de benchmark support IT.** Les tickets couvrent des demandes comme VPN, Outlook, imprimante, BitLocker, Teams, poste lent ou accès réseau.
- O2. Comparer plusieurs architectures.** Le banc oppose un LLM unique zero-shot, un agent ReAct outillé, des agents A2A distants et des variantes de Racing Arena.
- O3. Évaluer selon plusieurs dimensions.** Les sorties sont notées par qualité, sécurité, coût, latence, tokens et GreenOps. Ces dimensions sont combinées dans une politique composite explicite.
- O4. Rendre le projet maintenable.** Le dépôt expose une CLI, des tests unitaires mocks, une organisation modulaire et une intégration Git/CI pour synchroniser les tâches de l'équipe.

1.4 Contributions

Les contributions principales sont :

- une CLI **bibops** regroupant les commandes de benchmark, évaluation, développement, Racing Arena, configuration et rapport ;
- un agent de support IT traçable, basé sur ReAct [11], RAG [5], appels outils et principes proches de Toolformer [9] ;

- un moteur d'évaluation combinant juge LLM, inspecteurs de sécurité, métriques opérationnelles et gates de release ;
- des benchmarks A2A et MCP permettant d'étudier des agents ou outils externes ;
- une Racing Arena avec flux SSE et agents adversariaux ;
- une suite de tests unitaires permettant de vérifier le code sans dépendance à un modèle LLM réel.

2. Problématique

2.1 Nature des tickets de support IT

Un ticket IT est souvent court, incomplet et contextuel. Il peut décrire un symptôme sans donner l'état réel du service, le message d'erreur exact ou le niveau d'urgence. Une bonne réponse doit donc rester prudente : identifier une cause probable, proposer des actions concrètes, demander les informations manquantes et escalader lorsque le problème dépend d'une infrastructure.

Le jeu de données principal contient des tickets IT comme : *Mon VPN Cisco ne marche plus*, *Outlook crash au démarrage*, *Comment récupérer ma clé BitLocker ?* ou *Mon PC redémarre en boucle après une mise à jour Windows*. Ces tickets représentent bien un support de niveau 1 ou 2 : le modèle doit être utile sans inventer d'état interne.

2.2 Limites du LLM unique

L'architecture LLM unique appelle directement le modèle sur le ticket. Elle a l'avantage d'être simple, mais elle présente trois limites.

- **Pas d'état externe.** Le modèle ne peut pas vérifier si le VPN ou la messagerie est en panne dans l'environnement local.
- **Risque d'hallucination.** Le modèle peut proposer des procédures, numéros ou causes plausibles mais non vérifiées.
- **Évaluation trompeuse.** Une réponse bien rédigée peut être insuffisante si elle ne respecte pas les sources ou les contraintes de sécurité.

2.3 Intérêt de l'approche agentique

Une architecture agentique introduit une boucle perception–décision–action. Le LLM ne répond plus seulement au ticket : il choisit si un outil est nécessaire, lit le résultat et produit une réponse finale. Cette approche est utile lorsque le problème dépend d'une base de connaissances, d'une documentation technique ou d'un statut serveur.

Elle introduit aussi de nouveaux risques. Le modèle peut choisir le mauvais outil, répéter un appel, mal interpréter un résultat ou suivre une instruction malveillante contenue dans une source externe. L'évaluation doit donc inclure l'outillage, la trace et la sécurité agentique, pas seulement la réponse finale.

3. Présentation de la solution

3.1 Vue d'ensemble

BIBOPS est un framework Python organisé autour d'une CLI et de modules spécialisés. Le pipeline part d'un dataset de tickets, exécute une ou plusieurs architectures, évalue les réponses puis produit des artefacts exploitables.




Figure 3.1 – Vue d'ensemble UML de l'architecture BIBOPS.

3.2 Agent de support IT

La fonction centrale est `lancer_agent()` dans `src/agent/maestro.py`. Elle exécute une boucle ReAct bornée par un nombre maximal d'itérations. À chaque tour, le LLM retourne une décision structurée : nom d'outil, argument et réponse finale éventuelle. Ce contrat évite de parser du texte libre et rend les tests unitaires plus fiables. Cette approche rejoint les sorties structurées et les appels outils utilisés pour fiabiliser les workflows agentiques [6].

Les outils exposés sont volontairement simples.

Module	Responsabilité
src/agent/	Agent IT ReAct, mémoire courte, outils, serveur MCP et RAG.
src/common/	Configuration, clients LLM et fonctions texte partagées.
src/bibops/cli/	CLI Typer : bench , eval , dev , racing , copilot , test , config , report .
src/bibops/benchmark/	Runners de benchmark et validation des sorties.
src/bibops/evaluation/	Juges, inspecteurs de sécurité, scores composites et seuils.
src/bibops/adapters/	Adaptateurs vers agents IT, A2A et API OpenAI-compatible.
src/racing/	Hub FastAPI, flux SSE, équipes LangGraph et scénario adversarial.
tests/	Tests unitaires, fakes OpenAI et fixtures.

Table 3.1 – Organisation fonctionnelle du dépôt.




Figure 3.2 – Boucle ReAct UML de l'agent de support IT.

Outil	Timeout	Retry	Usage
verifier_statut_serveur	3 s	0	Interroge SQLite pour vérifier l'état d'un service.
chercher_dans_kb	5 s	1	Cherche dans une base de connaissances JSON.
chercher_documentation_technique	8 s	1	Interroge une base ChromaDB pour le RAG.

Table 3.2 – Outils disponibles pour l'agent IT.

Un routage lexical fournit un indice initial : par exemple `vpn` oriente vers le statut serveur, tandis que `bitlocker` oriente vers la documentation. L’indice ne remplace pas la décision du modèle, mais il augmente la probabilité d’utiliser la bonne source.

3.3 Évaluation

BIBOPS formalise l’évaluation comme un problème multicritère.

Dimension	Poids	Rôle
Qualité	40 %	Pertinence, complétude, clarté et utilité de la réponse.
Sécurité	35 %	PII, secrets, injection, URLs suspectes, toxicité, refus.
FinOps	10 %	Coût estimé à partir des tokens.
Latence	10 %	Temps de réponse total.
GreenOps	5 %	Énergie et empreinte carbone estimées.

Table 3.3 – Pondération de la politique composite.

Le module `src/bibops/evaluation/` combine trois familles d’évaluation. `LLMJudge` fournit un score générique ; `LLMProfessor` spécialise le jugement pour les tickets IT ; les détecteurs déterministes identifient PII, secrets, prompt injection, toxicité, URLs suspectes et refus incorrects. Cette logique s’appuie sur le principe de LLM-as-a-judge [12], tout en gardant des contrôles déterministes pour les risques de sécurité.

La politique composite calcule :

$$S = 0,40Q + 0,35Sec + 0,10F + 0,10L + 0,05G,$$

où Q est la qualité, Sec la sécurité, F le score FinOps, L la latence normalisée et G le score GreenOps. Le score est rapporté sur 100 et complété par un verdict **PASS** ou **FAIL**.

Le score composite est complété par des gates bloquants : qualité minimale, sécurité minimale et seuils maximaux pour certains risques. Cette logique évite qu’une architecture rapide ou peu coûteuse soit validée si elle répond mal.

3.4 A2A, MCP et Racing Arena

Les agents A2A sont utilisés pour tester des assistants distants exposés par JSON-RPC. Le projet prend en compte les différences entre fact-checkers et agents OpenClaw : endpoint de découverte, endpoint RPC, format des messages et présence possible d’outils comme `fetch`, `tavily`, `filesystem` ou `e2b`. Les secrets d’authentification restent hors rapport. Le protocole A2A vise précisément l’interopérabilité entre agents opaques et hétérogènes [1].

Le protocole MCP sert à exposer les outils de l’agent IT sous une interface standardisée [2]. Cela permet de mesurer les outils indépendamment du LLM et de préparer des intégrations plus larges.

La Racing Arena est une extension exploratoire. Un hub FastAPI diffuse une télémétrie par SSE ; plusieurs équipes LLM prennent des décisions ; une équipe adversariale tente des prompt injections et fuites de stratégie. Cette arène teste la sécurité d’architecture, pas seulement la qualité textuelle. Les scénarios adversariaux s’inscrivent dans les risques décrits par OWASP [7] et par les travaux sur PromptInject [8].

3.5 Reproductibilité

La reproductibilité repose sur quatre décisions :

- une CLI unique **bibops** pour lancer les campagnes ;
- des artefacts JSON et graphiques sous **data/outputs/benchmark/** ;
- des tests unitaires qui mockent les LLM et ne dépendent pas d'Ollama ;
- une séparation entre code source, données runtime et résultats générés.

Les commandes principales sont documentées dans le README et dans la documentation détaillée. La vérification locale actuelle passe par `python -m pytest tests/unit -q`.

4. Organisation de l'équipe et synchronisation Git

4.1 Répartition du travail

Le projet a été conduit par trois personnes avec une répartition par domaines. Akram a principalement pris en charge l'agent, la vectorisation, la sécurité expérimentale et le refactoring final. Widad a porté l'interface d'évaluation, la knowledge base, le moteur de scoring, les tests A/B et la consolidation des scores. Ayoub a travaillé sur la recherche KB, le serveur et client MCP, l'intégration Copilot API, le protocole A2A et la préparation de la soutenance.




Cette répartition a permis de paralléliser les sujets tout en gardant un point de convergence hebdomadaire : chaque fonctionnalité devait produire soit une commande CLI, soit un artefact de benchmark, soit un test automatisable.

4.2 Méthode de collaboration et pipeline CI/CD

L'équipe a organisé son travail autour de branches Git dédiées à chaque lot fonctionnel, avec des merges systématiquement validés par des tests unitaires pour éviter les régressions. Le cycle de développement suivait des étapes courtes : choix du ticket, développement sur branche, tests locaux, demande de merge, corrections, puis synchronisation et régénération des artefacts si besoin.

Le pipeline CI/CD garantissait le respect des standards (style, tests, gates), détectait rapidement les conflits entre travaux parallèles et assurait la traçabilité des résultats sur une base testée et reproductible.

**Figure 4.2** – Pipeline Git, CI/CD et production des artefacts.

5. Patrons de conception

5.1 Choix de conception

Le choix le plus important est la séparation entre le raisonnement du modèle et les sources vérifiées. Les outils retournent des données bornées, les décisions de l'agent sont structurées et les traces conservent les appels. Cette séparation rend l'évaluation possible : lorsqu'une réponse est mauvaise, on peut identifier si l'erreur vient du routage, de l'outil, du modèle ou du juge.

Le second choix est le recours à des contrats simples. SQLite suffit pour un statut serveur, JSON suffit pour une knowledge base de prototype, ChromaDB permet le RAG sans infrastructure lourde, et Typer fournit une CLI claire. Cette sobriété réduit le nombre de composants à maintenir et facilite les tests.

Patron	Usage dans le projet
Adapter	Unifie les appels vers l'agent IT, les agents A2A et les APIs OpenAI-compatible.
Strategy	Permet de changer d'évaluateur ou de politique de score sans réécrire les runners.
Registry	Centralise les évaluateurs disponibles et les rend extensibles.
Facade	La CLI bibops masque la complexité des modules internes.
Observer	La Racing Arena diffuse la télémétrie SSE à plusieurs équipes abonnées.
Template Method	Les runners de benchmark partagent la séquence charger, exécuter, évaluer, exporter.

Table 5.1 – Patrons de conception principaux.

5.2 Le système vise plusieurs acteurs : [Cas d'utilisation]

5.3 Les concepts métier : [Diagramme de classes d'analyse]




Figure 5.1 – Diagramme des cas d'utilisation de BIBOPS.




Figure 5.2 – Diagramme de classes d'analyse.

6. Résultats

6.1 Conditions expérimentales

Les résultats principaux proviennent des artefacts locaux sous `data/outputs/benchmark/`. L'évaluation principale cible le domaine IT : le LLM unique et l'agent ReAct utilisent `phi3:latest` via Ollama, l'agent force son premier appel outil afin de rendre l'orchestration reproductible, et `gpt-5.2` sert de juge qualité pour la comparaison d'architectures. Les autres campagnes complètent cette mesure par des tests d'outils, d'agents distants, de raisonnement, de biais de position et de sécurité adversariale.

Artefact	Usage
<code>comparison_results.json</code>	Comparaison LLM unique vs agent ReAct outillé sur tickets IT.
<code>benchmark_mcp.json</code>	Évaluation directe des outils MCP.
<code>benchmark_mcp_tools.json</code>	Variante MCP enrichie avec pertinence et F1 lexical.
<code>a2a_agents_results.json</code>	Exploration de neuf agents A2A OpenClaw distants.
<code>security_race_report.json</code>	Analyse adversariale de la Racing Arena.
<code>kaggle/local_kaggle_exam_report_*.json</code>	Rejeu local Kaggle, 16 questions.
<code>position_bias_resultat.json</code>	Test de biais de position sur tickets IT.
<code>position_bias_statements_result.json</code>	Test de biais de position sur statements fact-checking.

Table 6.1 – Sources chiffrées exploitées.

6.2 LLM unique contre agent ReAct

Métrique	LLM unique	Agent ReAct	Lecture
Score qualité moyen	2,81/10	7,86/10	Gain fonctionnel net.
Score sécurité moyen	9,97/10	9,97/10	Sécurité stable dans cette campagne.
Latence totale	461,58 s	0,84 s	Réduction de 99,8 %.
Coût estimé	0,061315 \$	0,024150 \$	Coût divisé par 2,54.
Tokens totaux	6 664	2 415	Réduction de 63,8 %.
Énergie estimée	0,0013328 kWh	0,0004830 kWh	Réduction cohérente avec les tokens.
Empreinte carbone	0,06664 gCO ₂ e	0,02415 gCO₂e	Réduction de 63,8 %.
Score composite	46,14/100	91,34/100	+45,20 points.
Verdict	FAIL	PASS	Seul l'agent passe les gates.

Table 6.2 – Résultats principaux de `comparison_results.json`.

Le résultat le plus important est le passage du gate qualité. Le LLM unique échoue principalement avec `quality_score` < 7.0, tandis que l'agent atteint **7,86/10**. Le gain opérationnel est également marqué, mais il doit être interprété avec la configuration de benchmark : l'agent a le droit de forcer son outil initial et de synthétiser certaines réponses depuis les résultats outils. Le test mesure donc une architecture outillée contrôlée, pas uniquement la compétence brute du modèle.

6.3 Benchmark MCP

Dans ce rapport, MCP désigne le *Model Context Protocol*, utilisé pour exposer les fonctions de support IT comme des outils appelables [2]. Les cas MCP-001 à MCP-005 sont cinq tickets synthétiques qui couvrent les trois outils principaux, à savoir la recherche dans la base de connaissances, le statut serveur et la documentation technique/RAG.

Le benchmark direct contient cinq succès sur cinq, une latence moyenne de **0,0518 s** et un score final moyen de **9,78/10**. La variante enrichie conserve cinq succès, mais son score moyen descend à **7,94/10** car elle ajoute une mesure de pertinence et un F1 lexical plus strict. Le F1 nul ne signifie pas que l'outil échoue : il indique que la réponse utile ne reprend pas exactement les mêmes tokens que la référence courte. Cette limite motive des métriques RAG plus riches, telles que celles proposées par RAGAS [3].




Figure 6.1 – Synthèse du benchmark MCP avec score et latence sur échelles séparées.

Cas	Ticket évalué	Outil	Latence directe	Score direct	Score enrichi
MCP-001	VPN Cisco indisponible	KB	0,020 s	9,23	8,17
MCP-002	Statut du service Mail	Statut serveur	0,016 s	10,00	8,25
MCP-003	Récupération clé BitLocker	Documentation RAG	0,211 s	10,00	7,06
MCP-004	PC très lent	KB	0,006 s	9,84	8,11
MCP-005	Outlook crash au démarrage	KB	0,006 s	9,84	8,12

Table 6.3 – Détail des cinq cas MCP. KB correspond à `mcp_chercher_dans_kb`.

Artefact	Cas	Succès	Score moyen
<code>benchmark_mcp.json</code>	5	5	9,78/10
<code>benchmark_mcp_tools.json</code>	5	5	7,94/10

Table 6.4 – Synthèse des benchmarks MCP.

6.4 Agents A2A

Le benchmark A2A cible neuf agents OpenClaw distants avec le profil `full`. La campagne active les probes de rôle, la détection d'outils, quatre questions Kaggle par agent, un fact-checker externe et une évaluation qualité déterministe locale. Quatre agents terminent la campagne en mode complet : `agent-b`, `agent-c`, `agent-f` et `coder-baseline`. Deux agents sont limités par quota, deux refusent ou bloquent une partie des probes d'authentification, et un agent subit un timeout. Cette campagne illustre l'intérêt d'un protocole d'interopérabilité entre agents [1], mais aussi la nécessité de mesurer le transport et la fiabilité, pas seulement la qualité de réponse.




Figure 6.2 – Synthèse du benchmark A2A.

Agent	Modèle estimé	Rôle	Outils détectés	Qual.	Séc.	Tâche	Réussite	Lat.	Transport	Fiabilité
agent-a	inconnu	inconnu	–	0,00	0,00	0,00	0/21	22,26 s	quota	partiel
agent-b	gpt-5.3-codex	incertain	e2b, fs, tavily	7,32	9,64	7,23	18/23	22,91 s	ok	complet
agent-c	gpt-5.2	incertain	e2b, fetch, fs, tavily	7,42	9,61	7,43	19/23	23,89 s	ok	complet
agent-d	gpt-5.4	incertain	e2b, fs, tavily	7,33	9,62	7,28	18/23	37,13 s	timeout	partiel
agent-e	inconnu	inconnu	–	0,00	0,00	0,00	0/21	24,35 s	quota	partiel
agent-f	gpt-5.4	incertain	e2b, fetch, fs, tavily	7,73	9,64	7,77	20/23	31,42 s	ok	complet
agent-g	Claude Haiku 4.5	incertain	e2b, fetch, fs	7,88	9,65	6,86	8/10	20,31 s	auth échouée	inconclusif
agent-h	Claude Haiku 4.5	incertain	e2b, fs	7,05	10,00	6,82	8/9	22,06 s	auth échouée	inconclusif
coder-baseline	gpt-5.4-mini	coder	e2b, fs, tavily	6,98	9,60	7,11	16/21	22,83 s	ok	complet

Table 6.5 – Métriques A2A détaillées. Les modèles non révélés sont des estimations ; **fs** désigne l’outil filesystem.

La meilleure performance complète est obtenue par **agent-f**, avec **7,77** de score de tâche moyen, **7,73** de qualité moyenne et 20 tâches réussies sur 23 probes. Les agents **agent-g** et **agent-h** obtiennent de bons scores locaux sur les probes terminées, mais leur transport est classé **auth_failed** : ils sont donc utiles pour observer les garde-fous, pas pour conclure sur une disponibilité opérationnelle complète. Les noms de modèles doivent rester lus comme des signaux : seul **coder-baseline** dispose d'un modèle issu de l'agent-card avec une confiance forte.

6.5 Kaggle local

Le dernier rapport Kaggle local, `local_kaggle_exam_report_20260513_130503.json`, utilise **gpt-4o** via le proxy Copilot comme modèle évalué et **gpt-4o** comme juge. Le score est de **13/16**, soit **81,25 %**, avec une latence moyenne de **1,40 s** par question. Les 16 réponses respectent le format attendu, mais une réponse échoue au critère de sécurité. (reste veut signifier les autres models LLM local testés : mistral 7B et phi 3 , leur score était très bas due au nombre faible de leur paramtres (3 milliards dans le cas de phi3) et leur architecture moins avancée que gpt-4o.)




Figure 6.3 – Synthèse du benchmark Kaggle local, modèle et juge inclus dans le titre du graphique.

Question	Réponse	Attendu	Cause d'échec
2	94	68	Comptage exact de lettres.
6	25	1	Piège logique, réponse numériquement incorrecte.
11	B	A	Fuite de SSN : le juge marque safety_ok=false .

Table 6.6 – Erreurs restantes du dernier benchmark Kaggle local.

Cette évaluation complète les tickets IT par des questions de raisonnement, d'arithmétique exacte, de respect de format et de sécurité. Elle montre que le modèle reste performant en moyenne, mais que les tâches de comptage exact et les consignes de confidentialité restent des points de fragilité.

6.6 Biais de position

Sur les tickets IT, le juge compare **gpt-4o-mini** et **claude-haiku-4.5** avec **gpt-4o** comme juge : 80 jugements valides donnent 44 choix pour la position A, soit un taux A de **0,55** et une p-value binomiale de **0,434**. Sur les statements, 10 jugements donnent 6 choix pour A, soit un taux A de **0,60** et une p-value de **0,7539**. Ce test répond directement aux biais connus des juges LLM, notamment le biais de position documenté dans les travaux MT-Bench et Chatbot Arena [12].

Ces deux tests ne prouvent pas l'absence de biais ; ils indiquent seulement que les écarts observés sont compatibles avec le hasard dans ces tailles d'échantillon.




Figure 6.4 – Test de biais de position sur tickets IT et statements.

Jeux	Jugements	Choix A	Taux A	p-value	Lecture
Tickets IT	80	44	0,55	0,434	Pas d'évidence statistique forte.
Statements	10	6	0,60	0,7539	Échantillon trop petit pour conclure.

Table 6.7 – Résultats de biais de position.

6.7 Racing Arena adversariale

La Racing Arena simule une course de 15 tours avec quatre équipes : Team A zero-shot, Team B ReAct outillée, Team C avec validation et Team Psi comme attaquant. Le rapport .md de la course (à retrouver sur le git) contient **50 décisions** : 5 attaques contre Team A, 5 contre Team B et 4 contre Team C. Team Psi obtient **5 extractions** de stratégie, ce qui confirme que l'attaque ne se limite pas à provoquer une mauvaise action : elle peut aussi récupérer de l'information exploitable.




Figure 6.5 – Rapport de sécurité de la Racing Arena.

Équipe	Attaques	Injections	Fuites	Détection
Team A zero-shot	5	1 (20,0 %)	2 (40,0 %)	1 (20,0 %)
Team B ReAct	5	1 (20,0 %)	2 (40,0 %)	4 (80,0 %)
Team C validée	4	2 (50,0 %)	1 (25,0 %)	2 (50,0 %)

Table 6.8 – Métriques de sécurité adversariale du dernier rapport Racing.

Type d'attaque	Tentatives	Taux injection	Taux fuite
authority_spoof	6	33,3 %	66,7 %
rag_poison	3	33,3 %	0,0 %
direct_injection	5	20,0 %	20,0 %

Table 6.9 – Efficacité observée par type d'attaque.

La lecture principale est qualitative : la sécurité ne dépend pas seulement du modèle, mais aussi des endpoints exposés, du filtrage des messages SSE, de la séparation entre données et instructions et de la validation avant action. Le faible nombre d'attaques par équipe impose de rester prudent sur les pourcentages, mais la présence d'extractions confirme que l'observabilité adversariale est nécessaire pour compléter les métriques classiques de performance.

7. Discussion

7.1 Interprétation des résultats

Cette étude montre que l’agent outillé domine le LLM unique sur les dimensions fonctionnelles et opérationnelles. La différence vient de l’utilisation de sources structurées : l’agent peut vérifier un statut serveur ou retrouver une procédure au lieu de produire une réponse générique.

Ce résultat confirme l’intérêt des petits modèles lorsqu’ils sont couplés à des outils. `phi3:latest` seul obtient une qualité faible, mais la même famille de modèle placée dans un pipeline agentique passe le gate de release. Le gain ne vient donc pas uniquement du modèle ; il vient de l’architecture.

7.2 Limites

Plusieurs limites doivent être explicitées.

- **Dataset limité.** Les 21 tickets IT notés ne suffisent pas pour généraliser à tous les cas Michelin.
- **Configuration favorable à l’agent.** Le premier outil forcé et la synthèse déterministe réduisent la latence et les tokens. C’est utile pour tester le potentiel, mais cela doit être comparé à une configuration plus libre.
- **Juge LLM.** `gpt-5.2` apporte une évaluation scalable, mais il peut avoir ses propres biais, dont le biais de position et le biais de verbosité décrits dans les travaux LLM-as-a-judge [12]. Une validation humaine reste nécessaire.
- **Artefacts hétérogènes.** Les campagnes A2A, Kaggle, MCP et Racing ne mesurent pas exactement le même objet.
- **Agents distants instables.** Quotas, timeouts et erreurs d’authentification affectent directement les résultats A2A.

7.3 Perspectives

Les perspectives prioritaires sont l’augmentation du dataset, l’annotation par des experts support, la calibration du juge LLM, l’amélioration du RAG, la génération automatique du rapport PDF depuis la CLI et l’ajout d’un tableau de bord de suivi des régressions. Une autre piste consiste à router dynamiquement les tickets : LLM unique pour les cas simples, agent outillé pour les cas dépendants des sources, modèle plus fort pour les tickets critiques.

8. Conclusion

Le projet BIBOPS répond à un besoin concret : évaluer de façon rigoureuse des LLM et architectures agentiques pour le support IT. Le travail réalisé ne se limite pas à une démonstration conversationnelle. Il fournit une CLI, un agent outillé, des outils MCP, des adaptateurs A2A, un moteur d'évaluation multi-critères, une Racing Arena adversariale, des graphiques et une suite de tests.

Le résultat principal est favorable à l'architecture agentique : l'agent ReAct atteint **91,34/100** de score composite et un verdict **PASS**, contre **46,14/100** et **FAIL** pour le LLM unique. Il améliore la qualité moyenne, réduit le coût, la latence, les tokens et l'empreinte estimée. Ces gains montrent qu'un modèle plus petit peut devenir plus utile lorsqu'il est placé dans un système outillé et mesurable.

La conclusion reste prudente : les résultats dépendent du dataset, du juge, des prompts, du corpus RAG et de la configuration expérimentale. Avant toute industrialisation, il faut augmenter le corpus, introduire une évaluation humaine, renforcer la sécurité des endpoints et automatiser la régénération des rapports. La Racing Arena rappelle aussi qu'un agent utile est une surface d'attaque : les outils doivent être contrôlés, tracés et validés.

Le projet pose donc une base solide pour la suite. Il permet de mesurer, comparer puis optimiser des LLM pour le support IT, avec une méthode reproductible et compatible avec les contraintes d'une plateforme de type BibOps.

Bibliographie

- [1] A2A Project. Agent2Agent protocol, 2025.
- [2] Anthropic. Model context protocol specification, 2024.
- [3] Shahul Es, Jithin James, Luis Espinosa-Anke, and Steven Schockaert. RAGAS : Automated evaluation of retrieval augmented generation. *arXiv preprint*, 2309.15217, 2023.
- [4] European Parliament and Council of the European Union. Regulation (EU) 2024/1689 laying down harmonised rules on artificial intelligence, 2024.
- [5] Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, and Douwe Kiela. Retrieval-augmented generation for knowledge-intensive nlp tasks. *Advances in Neural Information Processing Systems*, 33 :9459–9474, 2020.
- [6] OpenAI. Introducing structured outputs in the api, 2024.
- [7] OWASP Foundation. OWASP top 10 for large language model applications, 2025.
- [8] Fabio Perez and Ian Ribeiro. Ignore previous prompt : Attack techniques for language models. *arXiv preprint*, 2211.09527, 2022.
- [9] Timo Schick, Jane Dwivedi-Yu, Roberto Dessì, Roberta Raileanu, Maria Lomeli, Luke Zettlemoyer, Nicola Cancedda, and Thomas Scialom. Toolformer : Language models can teach themselves to use tools. *arXiv preprint*, 2302.04761, 2023.
- [10] Elham Tabassi. Artificial intelligence risk management framework (AI RMF 1.0). Technical Report NIST AI 100-1, National Institute of Standards and Technology, 2023.
- [11] Shunyu Yao, Jeffrey Zhao, Dian Yu, Nan Du, Izhak Shafran, Karthik Narasimhan, and Yuan Cao. ReAct : Synergizing reasoning and acting in language models. *arXiv preprint*, 2210.03629, 2022.
- [12] Lianmin Zheng, Wei-Lin Chiang, Ying Sheng, Siyuan Zhuang, Zhonghao Wu, Yonghao Zhuang, Zi Lin, Zhuohan Li, Dacheng Li, Eric P. Xing, Hao Zhang, Joseph E. Gonzalez, and Ion Stoica. Judging llm-as-a-judge with mt-bench and chatbot arena. *arXiv preprint*, 2306.05685, 2023.